机器学习分类方法：从线性判别到支持向量机

数计2401 李元博

2026 年 10 月 18 日

摘要

本报告以《Python机器学习：原理与实践》为核心阅读材料，系统梳理了机器学习从理论基石到非线性模型进阶的实践路线。全文首先提炼了贯穿全书的五大核心论点，重点剖析了泛化误差、偏差-方差分解与奥卡姆剃刀原则。在实践环节，报告在已有的线性分类示例（鸢尾花 Fisher 线性判别，训练 98.10%、测试 97.78%）基础上，进一步补充了支持向量机（SVM）的核心原理——包括最大间隔、支持向量、软间隔与合页损失，以及基于拉格朗日乘子法的对偶问题求解过程。

为了探索线性模型的能力边界，本报告选取**核函数**作为唯一改进方向，通过“线性核 vs RBF 核”的对比实验来验证核技巧的实际收益。实验采用纯 NumPy 实现的简化 SMO 算法求解软间隔对偶问题，并在严谨的分层 5 折 × 10 次重复交叉验证协议下报告准确率的均值与标准误。实验结果表明：在近线性数据（鸢尾花前两维特征）上，线性核与 RBF 核的 CV 准确率并列（99.33%），核方法无增益，印证了“简单优先”的奥卡姆剃刀思想；而在强非线性数据（同心圆数据集）上，RBF 核带来了显著的性能跃升（由线性核的 52.35% 提升至 100%），直观且深刻地印证了“核技巧通过隐式升维化解维灾难”的核心价值。报告所有结论均以教材理论、严格的交叉验证指标及已完成的独立代码结果为准。

目录

1 前人研究成果与发展脉络 **3**

2 引言 **4**

3 数学背景 **4**

3.1 凸集 4

3.2 分离超平面定理 5

3.3 对 SVM 的支撑 5

4 线性分类基线 **6**

4.1 数据与任务 6

4.2 模型与结果 6

5 SVM 原理 **6**
5.1 最大间隔与支持向量 7
5.2 软间隔与合页损失 8
5.3 对偶问题与求解 8
5.4 核函数与核技巧 9
5.5 SVM 与逻辑回归的异同 10

6 核函数实验 **10**
6.1 改进思路 10
6.2 实验设置 10
6.3 结果与分析 11
6.4 多维度评估：精确率、召回率、F1、ROC/AUC 与计算开销 13
6.5 敏感性分析 15
6.6 算法行为与核技巧的可视化 16

7 代码实现 **16**
7.1 核心算法与公式映射 16
7.2 SMO 算法关键细节 18
7.3 模型评估与数据防泄露 18

8 结论 **18**
8.1 主要研究结论 18
8.2 结论适用范围与局限 19
8.3 后续研究方向 19

1　前人研究成果与发展脉络

支持向量机（SVM）的思想深植于统计学习理论（Statistical Learning Theory）。自 20 世纪 60 年代起，其发展脉络呈现出清晰的演进轨迹。Vapnik 与 Chervonenkis 在 20 世纪 60 至 70 年代创立的 VC 维理论与结构风险最小化（Structural Risk Minimization, SRM）原则，突破了传统经验风险最小化的局限，为“在有限样本下同时控制经验风险与泛化风险”提供了严谨的统一框架[11]，这是 SVM 最根本的理论根基。

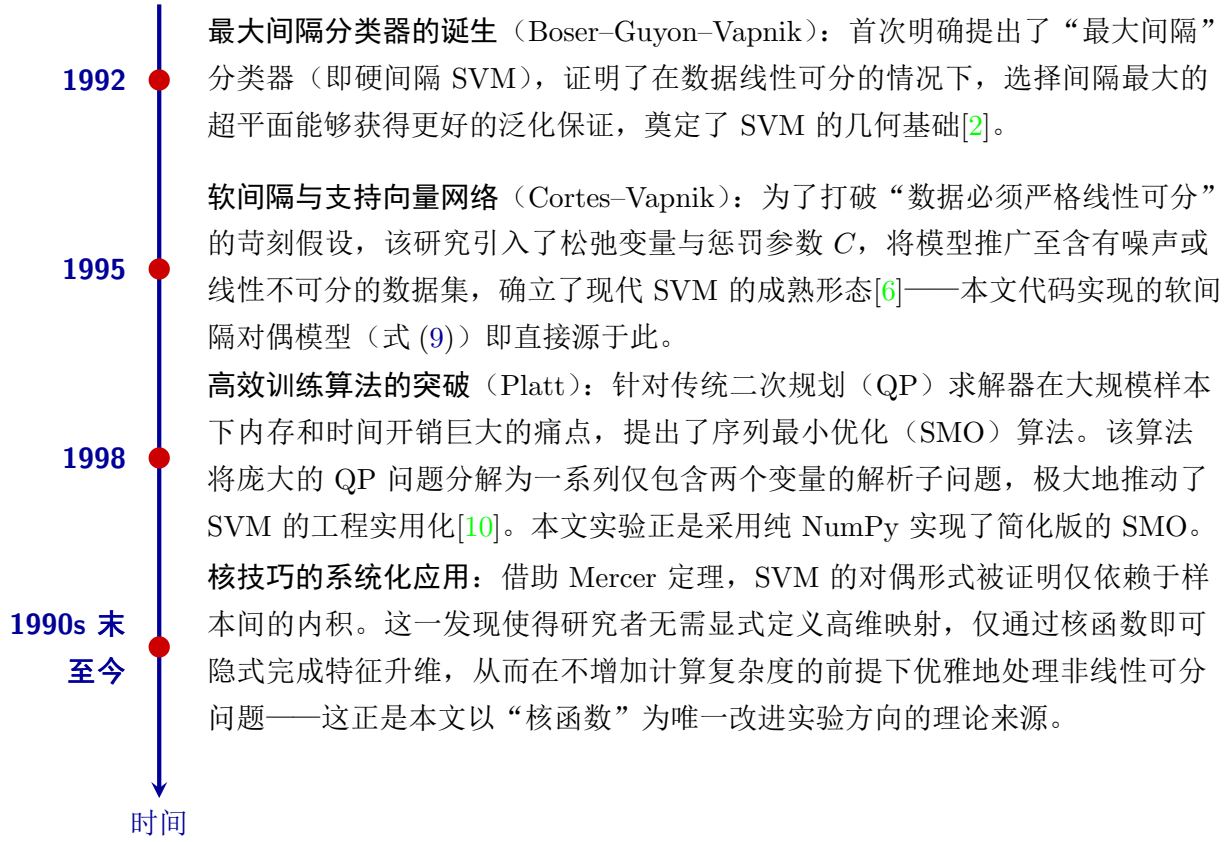


图 1: 支持向量机核心理论演进时间轴

上述时间轴清晰地勾勒了 SVM 从理论奠基、模型完善、算法加速到非线性扩展的完整演进脉络。这些核心思想将贯穿本文的后续章节：从最大间隔原则与支持向量的几何意义（第 5 节），到软间隔对偶问题与 SMO 算法的求解推导（第 5.3 节、第 7 节），再到核函数的数学原理与常见形式（第 5.4 节），最终落脚于以核函数为改进方向的对比实验（第 6 节）。本文试图通过这一逻辑主线，形成一条“从理论溯源到算法实现，再到实验验证”的完整闭环。

2 引言

线性方法是分类学习的起点，也是统计学习理论的基石：它们形式简洁、具有闭式解或凸优化解，且具备极强的可解释性。然而，线性模型的假设空间受限于线性决策边界（即超平面），当面对呈现复杂非线性结构的数据时，便不可避免地遭遇“欠拟合”而失效。

支持向量机（SVM）在保持“线性模型”数学框架的同时，巧妙地完成了向非线性分类的跨越。一方面，它通过**最大间隔**（Maximum Margin）原则控制模型复杂度，提升泛化能力；另一方面，它借助**核技巧**（Kernel Trick）在不显式计算高维映射的前提下，将线性方法自然推广到了非线性情形。因此，SVM 堪称是从线性通往非线性的最经典桥梁。

本文的结构安排如下：第 3 节交代其背后的数学基石（凸集与分离超平面定理）；第 4 节简要回顾线性分类基线模型；第 5 节深入剖析 SVM 的核心原理、软间隔对偶模型与训练机制；第 6 节给出以核函数为唯一改进方向的对比实验；第 7 节对照源码详细说明 SMO 算法的实现细节与数据流；第 8 节对全文进行总结与展望。

3 数学背景

在进入 SVM 的具体形式之前，先交代两项支撑其思想的核心数学理论——**凸集**与 **分离超平面定理**，并说明它们如何为 SVM 的几何直觉、间隔最大化与最优化求解提供理论依据。为保持全文符号一致，先约定记号：向量用粗体小写字母（如 $\mathbf{x}, \mathbf{w}, \mathbf{a}$）表示；两向量 $\mathbf{x}, \mathbf{y}$ 的 **内积**记为 $\mathbf{x}^{\mathsf{T}}\mathbf{y}$；$\mathbf{x}$ 的 **欧氏范数**记为 $\|\mathbf{x}\| = \sqrt{\mathbf{x}^{\mathsf{T}}\mathbf{x}}$。本节关于凸集与分离超平面的内容主要依据凸优化经典教材[3]。

3.1 凸集

定义（凸集）。集合 $C \subseteq \mathbb{R}^n$ 称为凸集，若对任意 $\mathbf{x}, \mathbf{y} \in C$ 与任意 $\theta \in [0, 1]$，其连线段整体仍在 C 中：

$$\theta\,\mathbf{x} + (1-\theta)\,\mathbf{y} \in C.$$

直观地说，凸集就是“任意两点之间的线段都整个落在集合内”的集合：圆盘、半平面、长方体、直线都是凸集；而圆环、十字形、空心星形则不是凸集。

SVM 将反复用到凸集的以下基本性质（均可由定义直接验证）：

1. **交集保持凸性**：任意多个凸集的交集仍是凸集。例如，多个半空间的交（多面体）是凸集。
2. **半空间与超平面是凸集**：对任意 $\mathbf{a} \neq \mathbf{0}$ 与 $b \in \mathbb{R}$，半空间 $\{\mathbf{x} : \mathbf{a}^{\mathsf{T}}\mathbf{x} \leq b\}$ 是凸集；超平面 $\{\mathbf{x} : \mathbf{a}^{\mathsf{T}}\mathbf{x} = b\}$ 也是凸集（且是仿射集）。
3. **仿射变换保持凸性**：凸集经线性（仿射）映射后的像仍是凸集。
4. **凸包**：集合 S 的**凸包** $\operatorname{conv}(S)$ 是包含 S 的最小凸集，等于 S 中点的全部凸组合；有限点集的凸包即这些点的最小凸多边形。

3.2 分离超平面定理

定义（分离）。设 $C, D \subseteq \mathbb{R}^n$。若存在 $\mathbf{a} \neq \mathbf{0}$ 与 $b \in \mathbb{R}$，使得

$$\mathbf{a}^{\mathsf{T}}\mathbf{x} \leq b \ \ (\forall \mathbf{x} \in C), \qquad \mathbf{a}^{\mathsf{T}}\mathbf{x} \geq b \ \ (\forall \mathbf{x} \in D), \tag{1}$$

则称超平面 $\{\mathbf{x} : \mathbf{a}^{\mathsf{T}}\mathbf{x} = b\}$ **（非严格）分离** C 与 D。若式 (1) 的不等号能取得**正间隙**，即存在 $\epsilon > 0$ 使 $\mathbf{a}^{\mathsf{T}}\mathbf{x} \leq b - \epsilon$ $(\forall \mathbf{x} \in C)$ 且 $\mathbf{a}^{\mathsf{T}}\mathbf{x} \geq b + \epsilon$ $(\forall \mathbf{x} \in D)$，则称该超平面**严格分离** C 与 D。

定理（分离超平面定理，非严格情形）。若 C 与 D 是**不相交的凸集**，则存在超平面（非严格）分离二者。

定理（严格分离情形）。若 C 与 D 是不相交的凸集，且二者之间距离为正（一个充分条件是：C, D 均为**闭**凸集且至少一个是**有界**的），则存在超平面**严格**分离二者。

两种情形务必区分：

- **非严格分离**只要求“不交叉”，允许超平面贴住甚至触及集合的闭包—— 此时不等式只能取 $\leq$ 与 $\geq$，没有正的间隙，两类样本可能紧挨着超平面；
- **严格分离**要求超平面两侧各留出一个**正间隙** ϵ，这需要两个凸集真正“被隔开一段正距离”才成立。

两个常用特例直接服务于 SVM：

1. **点与闭凸集的严格分离**：若 C 是闭凸集且 $\mathbf{x}_0 \notin C$，则存在 $\mathbf{a} \neq \mathbf{0}$，使得 $\mathbf{a}^{\mathsf{T}}\mathbf{x} < \mathbf{a}^{\mathsf{T}}\mathbf{x}_0$ 对一切 $\mathbf{x} \in C$ 成立。
2. **支撑超平面**：若 $\mathbf{x}_0$ 是凸集 C 的边界点，则存在 $\mathbf{a} \neq \mathbf{0}$，使得超平面 $\{\mathbf{x} : \mathbf{a}^{\mathsf{T}}\mathbf{x} = \mathbf{a}^{\mathsf{T}}\mathbf{x}_0\}$ 把整个 C 支撑在一侧（即 $\mathbf{a}^{\mathsf{T}}\mathbf{x} \leq \mathbf{a}^{\mathsf{T}}\mathbf{x}_0$ 对一切 $\mathbf{x} \in C$ 成立）。

3.3 对 SVM 的支撑

上述两项理论为 SVM 的“几何直觉—间隔最大化—最优化求解”提供了完整依据：

1. **几何直觉：分离超平面定理保证分类超平面的存在**。若两类样本线性可分，则两类的凸包 $\mathrm{conv}(C_1)$ 与 $\mathrm{conv}(C_0)$ 是不相交的凸集（教材第 8.3 节的“凸包构造”正是据此而来）。由分离超平面定理，存在超平面把二者分开，它即可作为分类超平面 $\mathbf{w}^{\mathsf{T}}\mathbf{x} + b = 0$。
2. **间隔最大化：严格分离提供可优化的正间隙**。当两类凸包之间存在正距离时，严格分离定理保证存在正间隙 $\epsilon > 0$；SVM 进而要在所有可行分离超平面中选“间隙最宽”者，即最大化边界宽度 $\lambda = 2/\|\mathbf{w}\|$ （式 (3)）。目标函数 $\frac{1}{2}\|\mathbf{w}\|^2$ 严格凸，故最大间隔超平面**唯一存在**。
3. **最优化求解：凸性保证问题的“好性质”**。目标 $\frac{1}{2}\|\mathbf{w}\|^2$ 是严格凸函数，约束 $y_i(\mathbf{w}^{\mathsf{T}}\mathbf{x}_i + b) \geq 1$ 是仿射（线性）约束，故原始问题是一个**凸二次规划**。凸优化的核心结论——局部最优即全局最优、 KKT 条件充分必要、强对偶成立（对偶间隙为零，凸二次规划满足 Slater 条件）——为第 5.3 节的对偶推导与 SMO 求解提供了正确性与收敛性保证。

4 线性分类基线

4.1 数据与任务

为了直观展示线性模型的几何特性，本节选用经典的 UCI Iris 数据集[7]。具体而言，我们仅提取前两个物理特征——萼片长度（sepal length）与萼片宽度（sepal width），并将原三分类问题化简为二分类任务：将 setosa 类标记为正类（$y=1$），将其余两类（versicolor 与 virginica）合并为负类（$y=0$），共计 $n=150$ 个样本。这前两维特征不仅便于在二维平面上直接绘制决策边界，也能很好地体现 setosa 与其他类别的分布差异。

作为全篇的线性基线，本节采用**单次** $7:3$ 的训练集与测试集划分（固定随机种子 `default_rng(42)`）。需要说明的是，单次划分的结果容易受数据划分随机性的影响，此处仅作示例性展示；在第 6 节中，我们将改用更严谨的分层 5 折 $\times$ 10 次重复交叉验证来进行无偏的性能评估。

4.2 模型与结果

Fisher 线性判别分析（LDA）的核心思想是寻找一个投影方向，使得两类样本在该方向上的投影点尽可能分离（类间方差最大化），同时同类样本的投影尽可能紧凑（类内方差最小化）。该模型存在完美的闭式解：

$$\mathbf{w}=\mathbf{S}_w^{-1}(\boldsymbol{\mu}_1-\boldsymbol{\mu}_0),\qquad b=-\mathbf{w}^{\mathsf{T}}\left(\frac{\boldsymbol{\mu}_1+\boldsymbol{\mu}_0}{2}\right), \tag{2}$$

其中 $\mathbf{S}_w$ 为类内散布矩阵（Within-class scatter matrix）。在得到法向量 $\mathbf{w}$ 与偏置 b 后，分类决策规则为 $\hat{y}=\operatorname{sign}(\mathbf{w}^{\mathsf{T}}\mathbf{x}+b)$（约定 $g>0$ 判为正类）。

在本数据集上估计得到的参数为：$\mathbf{w}=(-0.0672,\,0.1163)^{\mathsf{T}}$，$b=0.0150$。这一权重向量表明，萼片宽度（$x_2$）的系数绝对值略大于萼片长度（$x_1$），说明在该二维平面上，宽度特征对于区分 setosa 起到了更关键的判别作用。由此得到的线性决策边界方程为 $x_2\approx 0.5774\,x_1-0.1291$。

在性能表现上，该基线模型取得了训练准确率 98.10%、测试准确率 97.78% 的优良效果。通过分析混淆矩阵可知，150 个样本中仅有 3 个被误分类（训练阶段假阳性 FP$=2$，测试阶段假阴性 FN$=1$）。这一结果直观地说明：setosa 类别在萼片特征空间中与其余类别呈现**近似**（而非**完全**）线性可分的状态，两类分布在边界附近存在轻微的重叠（如图 2 所示）。

遗留问题：尽管 LDA 在本例中表现优异，但其本质局限在于决策边界只能是一条直线（在高维空间中为超平面）。一旦面对具有复杂非线性结构的数据（例如环形分布、异或问题或高度纠缠的特征空间），仅凭一条直线无论如何平移或旋转都无法完成有效切割，线性方法将不可避免地失效。为了在保留线性模型简洁性的同时突破这一几何限制，我们将在下一节引入支持向量机（SVM），并探讨最大间隔原则与核方法如何巧妙化解这一难题。

5 SVM 原理

SVM 由 Boser、Guyon 与 Vapnik 于 1992 年提出，建立在统计学习理论基础上，在小样本、非线性与高维问题上具有优势（本章内容主要依据教材[1]第 8 章）。其核心思想可概括为：**在能正确划**

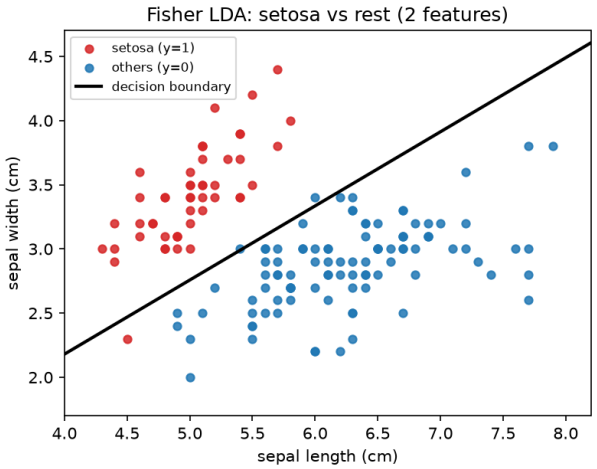


图 2: 线性基线：Fisher LDA 在鸢尾花前两维上的决策边界（训练 98.10%、测试 97.78%）。

分两类的超平面中，选择“离两类边缘观测点最远”的那一个，即最大间隔超平面。

5.1 最大间隔与支持向量

设分类超平面为 $b + \mathbf{w}^{\mathsf{T}}\mathbf{x} = 0$（标签约定 $y \in \{-1, +1\}$）。为了使得分类具有尽可能高的置信度，SVM 不仅仅满足于将两类样本分开，而是追求一个“最宽敞”的隔离带。在 SVM 的尺度约定下，两类边界线分别为 $b + \mathbf{w}^{\mathsf{T}}\mathbf{x} = \pm 1$，根据点到平面的距离公式，这两条平行线之间的间距（即**边界宽度**，Margin）为

$$\lambda = \frac{2}{\|\mathbf{w}\|}. \tag{3}$$

直观上，边界越宽，样本点距离决策边界就越远，模型对未见数据的预测置信度就越高，从而泛化能力越强。

为了保证所有样本都被正确分类且不落入隔离带内，需要满足严格的几何约束：$y_i\,(b + \mathbf{w}^{\mathsf{T}}\mathbf{x}_i) \geq 1$。由于最大化边界宽度 λ 等价于最小化分母 $\|\mathbf{w}\|$，为了避免求根带来的非凸优化问题，通常将其转化为最小化 $\frac{1}{2}\|\mathbf{w}\|^2$。于是，最大间隔原则在数学上等价于如下凸二次规划（原问题）：

$$\min_{\mathbf{w},b} \ \frac{1}{2}\|\mathbf{w}\|^2 \qquad \text{s.t.} \quad y_i\big(b + \mathbf{w}^{\mathsf{T}}\mathbf{x}_i\big) \geq 1, \quad i = 1, \ldots, N. \tag{4}$$

对于上述带约束的凸优化问题，引入拉格朗日乘子 $\alpha_i \geq 0$ 构造拉格朗日函数，并利用 KKT 条件中的**互补松弛性**（Complementary Slackness），可得到如下核心等式：

$$\alpha_i \left[\, y_i f(\mathbf{x}_i) - 1 \,\right] = 0$$

这一条件揭示了 SVM 极其优雅的稀疏结构：

- 当样本位于隔离带之外（即 $y_i f(\mathbf{x}_i) > 1$）时，括号内项大于零，必须满足 $\alpha_i = 0$。这意味着这些被完美且轻松分类的样本，对最终超平面的参数求解**不起任何作用**。

- 当且仅当 $\alpha_i > 0$ 时，必须满足 $y_i f(\mathbf{x}_i) = 1$，即这些样本恰好**落在两类边界线上**。它们被称为**支持向量（Support Vectors）**。

因此，最终的分类超平面**完全由支持向量决定**，与大量非支持向量无关。这种仅依赖关键边界样本的特性，使得 SVM 在面对冗余数据或微小扰动时表现得极其稳定——这正是 SVM 鲁棒性的根本来源。

5.2 软间隔与合页损失

在现实任务中，数据往往包含噪声或异常点，完全线性可分（即硬间隔）的约束过于严苛，强行追求完全无误的分类极易导致模型过拟合。为此，我们允许部分样本适度“越界”（即允许它们被分错，或者落入间隔带内部）：引入**松弛变量**（Slack Variables）$\xi_i \geq 0$。这里的 ξ_i 可以理解为模型赋予每个样本的“违规额度”，约束随之放松为 $y_i(b + \mathbf{w}^\mathsf{T}\mathbf{x}_i) \geq 1 - \xi_i$，优化目标变为

$$\min_{\mathbf{w},b,\boldsymbol{\xi}} \ \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{N}\xi_i. \tag{5}$$

式中的**惩罚参数** $C > 0$ 扮演着“平衡器”的角色，用于折中“边界宽度”与“训练误差”：C 越大，意味着模型对违规样本的惩罚越重，对误差的容忍度极低，这会迫使模型压缩边界以容纳所有点，导致边界变窄且易过拟合；反之，C 越小，模型越倾向于“抓大放小”，允许更多样本越界以换取更宽、更平滑的决策边界（模型更简单）。

从损失函数的角度看，式 (5) 与带 **合页损失（Hinge Loss）**的正则化目标完全等价：

$$\min_{\mathbf{w},b} \ \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{N}\max\bigl(0,\ 1 - y_i\, f(\mathbf{x}_i)\bigr), \qquad f(\mathbf{x}) = \mathbf{w}^\mathsf{T}\mathbf{x} + b, \tag{6}$$

之所以称为“合页”，是因为其函数图像呈现出一个类似门合页的折线形状。该损失函数的物理意义非常直观：若样本被正确分类且不仅分对，而且距离边界的安全余量不小于 1（即 $y_i f(\mathbf{x}_i) \geq 1$），则模型对其“零惩罚”（损失为 0）；若样本越界或误分，则损失随着违规程度线性增长。这种设计不仅惩罚了“分错的样本”，也惩罚了“分对了但置信度不够（离边界太近）”的样本。

在软间隔机制下，最终求得的支持向量不仅包括恰好落在边界线上的点（此时 $\xi_i = 0$），还包括那些滑入间隔带“禁区”内甚至被分错的点（此时 $\xi_i > 0$，对应的拉格朗日乘子达到上限 $\alpha_i = C$）。

5.3 对偶问题与求解

式 (5) 是一个带线性不等式约束的凸二次规划。为了便于求解，我们引入拉格朗日乘子 $\alpha_i \geq 0$（对应分类约束）与 $\mu_i \geq 0$（对应 $\xi_i \geq 0$），通过构造拉格朗日函数将带约束的优化问题转化为无约束的极值问题：

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_i \xi_i - \sum_i \alpha_i\bigl[y_i(\mathbf{w}^\mathsf{T}\mathbf{x}_i + b) - 1 + \xi_i\bigr] - \sum_i \mu_i\xi_i. \tag{7}$$

由**KKT 条件**的驻点条件 $\partial\mathcal{L}/\partial\mathbf{w} = 0$、 $\partial\mathcal{L}/\partial b = 0$ 得

$$\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i, \qquad \sum_i \alpha_i y_i = 0. \tag{8}$$

这表明最终的权重向量 $\mathbf{w}$ 本质上是训练样本的线性组合。同时，$\partial\mathcal{L}/\partial\xi_i = 0$ 给出 $C - \alpha_i - \mu_i = 0$，故 $\alpha_i = C - \mu_i \le C$，即软间隔下每个样本的拉格朗日乘子都被惩罚参数 C 约束了上限。

进一步结合互补松弛条件 $\alpha_i[y_i f(\mathbf{x}_i) - 1 + \xi_i] = 0$ 可知：$\alpha_i > 0$ 当且仅当样本落在边界上或越界（即支持向量），而 $\alpha_i = 0$ 的样本对超平面完全不起作用——这正是第 5.1 节“超平面仅由支持向量决定”的推导来源。

将式 (8) 回代到 $\mathcal{L}$ 中消去 $\mathbf{w}, b, \boldsymbol{\xi}$，即得只含 $\boldsymbol{\alpha}$ 的**对偶问题**：

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{N} \alpha_i - \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N} \alpha_i \alpha_j y_i y_j \,(\mathbf{x}_i^{\mathsf{T}}\mathbf{x}_j) \qquad \text{s.t.} \quad \sum_{i=1}^{N} \alpha_i y_i = 0, \;\; 0 \le \alpha_i \le C. \tag{9}$$

这一转化极其关键：优化变量从高维的权重 $\mathbf{w}$ 变为了与样本数相同的标量 α_i，且目标函数中仅保留了样本间的内积项 $\mathbf{x}_i^{\mathsf{T}}\mathbf{x}_j$，这为后续引入核技巧铺平了道路。

求解得到 $\boldsymbol{\alpha}$ 后，偏置由支持向量平均得到：$b = y_i - \sum_j \alpha_j y_j (\mathbf{x}_j^{\mathsf{T}}\mathbf{x}_i)$，预测函数为

$$h(\mathbf{x}_0) = \operatorname{sign}\Big[b + \sum_{i \in SV} \alpha_i y_i (\mathbf{x}_i^{\mathsf{T}}\mathbf{x}_0)\Big]. \tag{10}$$

可以看到，最终的预测仅需计算待测样本与少数几个支持向量（SV）的内积，计算效率很高。

求解对偶问题的经典算法是 **SMO（Sequential Minimal Optimization）**。其核心思想是“分而治之”：由于存在等式约束 $\sum \alpha_i y_i = 0$，不能只更新单个变量，因此每次固定其余变量、只优化一对 (α_i, α_j)。该两变量子问题有解析解，反复选择违反 KKT 条件最严重的乘子对进行更新，直至全部满足 KKT 条件。本文实验即采用纯 NumPy 实现的简化版 SMO（随机选取乘子对）。

5.4 核函数与核技巧

观察式 (9) 和预测函数可以发现，无论是优化目标还是最终的决策规则，**都只依赖于样本间的内积 $\mathbf{x}_i^{\mathsf{T}}\mathbf{x}_j$**。这一特性为处理非线性问题提供了巧妙的突破口：如果我们能定义一个核函数，将样本经非线性映射 $\boldsymbol{\phi}$ 送入高维空间，那么只需让核函数满足

$$K(\mathbf{x}_i, \mathbf{x}_j) \;\equiv\; \boldsymbol{\phi}(\mathbf{x}_i)^{\mathsf{T}}\boldsymbol{\phi}(\mathbf{x}_j), \tag{11}$$

我们便能在原空间中直接计算 K，以此来替代高维空间中的内积运算。这意味着**无需显式升维、也无需知道 $\boldsymbol{\phi}$ 的具体形式**，就能实现高维特征空间中的线性划分，从而有效避开高维带来的维灾难——这正是 SVM 处理线性不可分数据的关键所在。

常用的核函数包括：

- 线性核：$K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^{\mathsf{T}}\mathbf{x}_j$，适用于数据本身近似线性可分的情形；
- d 阶多项式核：$K = (1 + \gamma\,\mathbf{x}_i^{\mathsf{T}}\mathbf{x}_j)^d$，通过多项式组合捕捉特征间的交互关系；
- 径向基核（RBF，最常用）：$K = \exp\!\big(-\gamma\|\mathbf{x}_i - \mathbf{x}_j\|^2\big)$，其中 $\gamma = 1/(2\sigma^2)$，能够拟合极其复杂的非线性边界。

然而，并非任意二元函数都能充当核函数。由 Mercer 定理可知，一个对称函数 K 若要成为合法核函数，其对应的核矩阵必须满足半正定性，等价地，对任意平方可积函数 g 需满足：

$$\iint K(\mathbf{x}, \mathbf{z})\, g(\mathbf{x}) g(\mathbf{z})\, \mathrm{d}\mathbf{x}\, \mathrm{d}\mathbf{z} \ge 0.$$

满足此条件时，必然存在特征映射 ϕ 使得 $K(\mathbf{x},\mathbf{z}) = \phi(\mathbf{x})^{\mathsf{T}}\phi(\mathbf{z})$ 成立。线性核与 RBF 核均满足该条件，因此对偶问题式 (9) 中的内积可被合法地替换为核函数。这也是代码中 `rbf_kernel` 函数返回的 Gram 矩阵（即核矩阵）能够直接送入 SMO 求解器进行优化的理论保证。

在 RBF 核中，参数 γ 直观地控制了单个训练样本的“影响半径”：γ 越小，单个样本的影响范围越远，决策面整体趋于平滑（倾向欠拟合）；γ 越大，影响范围越收缩于样本附近，决策面越容易围绕个别样本弯曲（倾向过拟合）。这一从“欠拟合到过拟合”的翻转行为，将在第 6.3 节的 γ 扫描实验中得到定量的验证。

5.5 SVM 与逻辑回归的异同

尽管 SVM 与逻辑回归（Logistic Regression, LR）同为经典的线性分类器，且都能通过正则化控制过拟合，但在损失函数设计上存在本质区别。逻辑回归采用对数损失（Log Loss）：

$$\mathcal{L}_{\mathrm{LR}} = \sum_{i=1}^{N} \log(1 + \exp(-y_i f(\mathbf{x}_i))),$$

而 SVM 采用合页损失（Hinge Loss）。从最优化结果来看，Log Loss 是平滑且严格单调递减的，因此 LR 会给所有样本分配一个非零权重；而 Hinge Loss 在 $y_i f(\mathbf{x}_i) > 1$ 的区域导数恒为 0，这导致了 SVM 中大量样本的 $\alpha_i = 0$——即**SVM 仅由支持向量决定，而 LR 由全量数据决定**。前者赋予了 SVM 极强的鲁棒性与稀疏性，后者则能输出具有概率意义的置信度。

6 核函数实验

6.1 改进思路

面对线性基线的局限，可供选择的改进方向包括核函数、参数调优和特征工程等。本文选择以**核函数**作为唯一的改进方向，主要基于以下原因：

- 核函数直接针对了线性模型决策边界只能是直线（或超平面）的局限，能够有效处理非线性分布的数据；
- 该方向与教材第 8.5 节“线性不可分：核函数技巧”的内容相对应，便于将理论学习转化为具体实践；
- 在工程实现上，核函数与第 5.3 节推导的对偶形式兼容性极好。在算法流程上，只需将内积 $\mathbf{x}_i^{\mathsf{T}}\mathbf{x}_j$ 替换为 $K(\mathbf{x}_i,\mathbf{x}_j)$ 即可，无需改动训练与预测的核心逻辑。

实验预期如下：在近线性的鸢尾花数据上，引入核方法后模型性能应不出现明显退化；在非线性数据上，核方法应能体现出其处理复杂边界的优势。

6.2 实验设置

- **算法实现**：采用纯 NumPy 编写的简化版 SMO 算法求解软间隔对偶问题（式 (9)），标签内部转换为 $y \in \{-1,+1\}$。为保证结果可复现，固定了随机数源；

- **评估协议**：采用**分层 5 折 × 10 次重复交叉验证**替代单次 7 : 3 划分。分层抽样确保每折中 setosa 与其余类的比例接近总体的 50 : 100；重复 10 次（种子 $42, \ldots, 51$）计算准确率的**均值与标准误**，以区分模型差异与数据划分带来的随机波动（交叉验证与 bootstrap 的方差特性比较见[9]）；
- **模型选择**：采用**一倍标准误（1se）规则**，即在交叉验证准确率不低于“最优均值减一个标准误”的模型中，优先选择最简单的模型。这是奥卡姆剃刀原则在参数选择上的具体落地（详见第 6.3 节）；
- **超参数控制**：为集中评估核函数的作用，实验固定惩罚参数 $C = 1.0$ 及 RBF 核基准参数 $\gamma = 0.5$。本节不进行网格搜索调参，以排除其他因素的干扰；关于 γ 与 C 的敏感性分析将在第 6.5 节单独讨论；
- **数据预处理**：考虑到 RBF 核依赖特征距离计算，对数据量纲较为敏感，SVM 使用训练折的均值与方差进行 Z-score 标准化。标准化过程仅在训练折上拟合，避免测试集信息泄露；
- **数据集配置**： A. 鸢尾花前两维（近线性可分，$n = 150$），用于检验核方法在简单数据上是否会产生额外开销或过拟合； B. 同心圆合成数据（外环 $y = 0$、内圆 $y = 1$，半径 1 与 0.5，噪声 $\sigma = 0.05$，$n = 200$），用于评估核方法在强非线性结构上的实际收益。

6.3 结果与分析

表 1: 实验 A：鸢尾花（近线性可分）——CV 四项指标（分层 5 折 × 10 次重复，单位：%，均值 ± 标准误）

方法	CV 准确率	精确率	召回率	F1 分数
Fisher LDA（基线）	98.20 ± 0.39	96.93 ± 0.57	98.00 ± 0.63	97.35 ± 0.58
线性核 SVM	99.33 ± 0.21	100.00 ± 0.00	98.00 ± 0.63	98.95 ± 0.33
RBF 核 SVM	99.33 ± 0.21	100.00 ± 0.00	98.00 ± 0.63	98.95 ± 0.33

表 2: 实验 B：同心圆（强非线性）——CV 四项指标（分层 5 折 × 10 次重复，单位：%，均值 ± 标准误）

方法	CV 准确率	精确率	召回率	F1 分数
线性核 SVM	52.35 ± 1.40	51.97 ± 1.14	62.70 ± 1.60	56.63 ± 1.30
RBF 核 SVM	100.00 ± 0.00	100.00 ± 0.00	100.00 ± 0.00	100.00 ± 0.00

结果分析：

1. **核函数带来明显提升（核心结论）**：在强非线性的同心圆数据上，线性核 SVM 的 CV 准确率仅 $52.35\% \pm 1.40\%$——一条直线无论如何摆放都无法分离同心圆（图 3 左），近乎随机猜测；换用 RBF 核后 CV 准确率升至 100.00%，**提升约 47.65 个百分点**（表 2），直观验证了核技巧

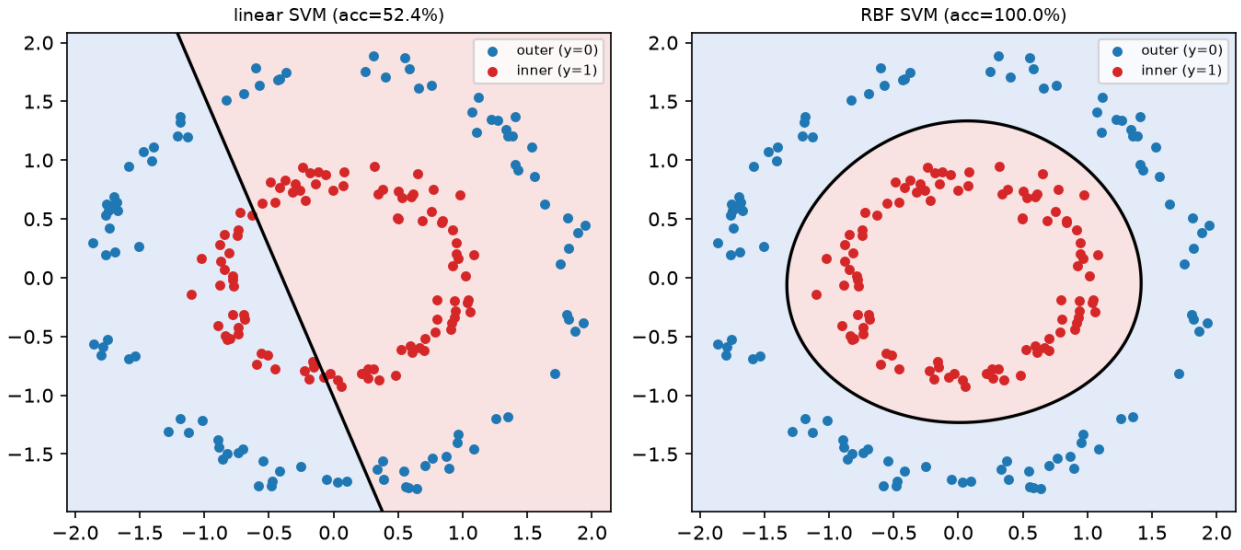


图 3: 同心圆数据上的决策边界对比：线性核只能画一条直线（CV 52.35%，几乎随机猜测）；RBF 核学习出圆形边界，完全分离两类（CV 100%）。

表 3: 实验 C：γ 扫描（鸢尾花，$C = 1$）——训练/CV 准确率与支持向量数随 γ 的变化（分层 5 折 $\times$ 5 次重复的均值）

γ	训练准确率	CV 准确率	支持向量数
0.001	66.67%	66.67%	81
0.003	69.63%	69.47%	81
0.01	99.33%	99.33%	69
0.03	99.33%	99.33%	41
0.1	99.33%	99.33%	26
0.32	99.33%	99.33%	21
1.0	99.33%	99.33%	27
3.2	100.00%	99.33%	53
10	100.00%	95.87%	94
32	100.00%	90.27%	112
100	100.00%	80.53%	118

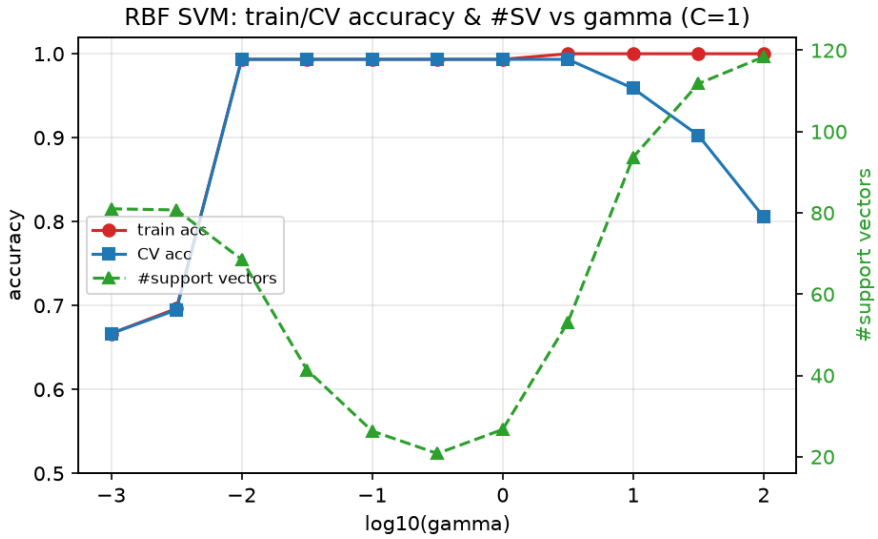


图 4: 固定 $C = 1$ 扫描 γ：低 γ 欠拟合（训练与 CV 都低）、中间 γ 最优（CV 平稳在 99.33%、支持向量数最低）、高 γ 过拟合（训练 100% 而 CV 快速下降、支持向量数激增）。

“隐式升维”的价值。

2. **近线性数据上核方法无增益（但不劣化）**：鸢尾花上线性核与 RBF 核的 CV 准确率**完全相同**（均为 $99.33\% \pm 0.21\%$，表 1），说明数据本就近乎线性可分时，引入核函数并不必要。
3. **1se 规则的实际执行**：鸢尾花上最优 CV 为 99.33%（线性核与 RBF 核并列），标准误 0.21%，1se 阈值为 99.12%。Fisher LDA 的 98.20% 低于该阈值（差距 1.13 个百分点 > 1 个标准误），故被判定为“显著更差”；线性核与 RBF 核并列于阈值之上，此时应选**更简单的线性核**——即“核方法在本设定下未提供超出随机波动的收益”。这与第 4 节单次划分的 97.78% 略有出入，因为重复交叉验证消除了单次划分的随机波动，结论更可靠。
4. γ **扫描：从欠拟合翻转到过拟合**（表 3、图 4）：γ 过小（≤ 0.003）时 RBF 核过宽，训练与 CV 都低（约 67%），属**欠拟合**；$\gamma \in [0.01, 3.2]$ 时 CV 平稳在 99.33%，属**最优区**；$\gamma \geq 10$ 时训练升至 100% 而 CV 快速下降到 80–96%，训练—CV 差距首次超过 5 个百分点（$\gamma \approx 32$），属**过拟合**。支持向量数呈 U 形：欠拟合与过拟合两端都高（81 与 118），最优 γ（≈ 0.3）处最低（21），印证“支持向量越多、模型对训练集贴合越紧、方差越大”的复杂度叙事。
5. **正确性说明（0-1 损失与偏差—方差分解）**：本文报告的准确率是 **0-1 损失**下的指标。偏差—方差的非负三项分解是**平方误差损失** 的专属性质，对 0-1 损失不存在同样“干净”的分解[8]。因此本文只用“训练—CV 差距随复杂度上升”作为过拟合的**定性**指示，不声称从 0-1 准确率中“分解出”了偏差与方差。

6.4 多维度评估：精确率、召回率、F1、ROC/AUC 与计算开销

仅以准确率评价分类器并不完整：在类别失衡或错误代价不对称时，准确率可能掩盖模型的真实行为。为此，本节从三个维度拓宽评估指标：（1）**精确率（Precision）**——被判为正类的样本中

真正为正类的比例， $\mathrm{P} = \mathrm{TP}/(\mathrm{TP}+\mathrm{FP})$；（2）**召回率（Recall）**——真实正类样本中被正确识别的比例， $\mathrm{R} = \mathrm{TP}/(\mathrm{TP}+\mathrm{FN})$；（3）**F1 分数**——二者的调和平均，$\mathrm{F1} = 2\mathrm{PR}/(\mathrm{P}+\mathrm{R})$。三者均由第 5 节软间隔支持向量所对应的混淆矩阵量（TP/FP/FN）直接计算（表 1、表 2 已加入这三列）。

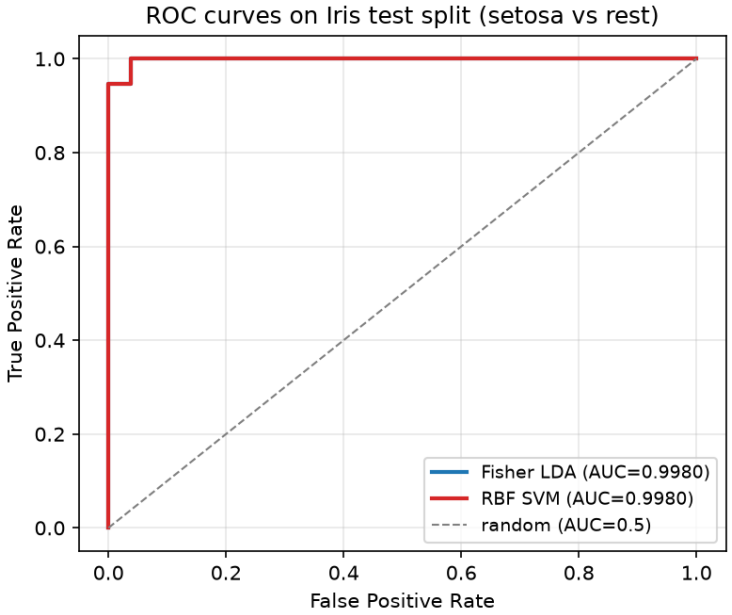


图 5: 鸢尾花测试划分（7 : 3，种子 42）上 Fisher 判别与 RBF 核 SVM 的 ROC 曲线对比。两者 AUC 均为 0.9980，曲线几乎重合并紧贴左上角，远优于随机猜测（对角线，AUC = 0.5）——说明在该近线性可分数据上，两种方法对判别阈值的选择均不敏感、排序能力几乎相同。

图 5 给出 Fisher 判别与 RBF 核 SVM 在鸢尾花测试划分上的 ROC 曲线：二者 AUC 完全相同（0.9980），曲线紧贴左上角，几乎重合。这与表 1 的结论一致——在近线性可分数据上，线性方法与核方法的**排序能力**（跨所有判别阈值的整体表现）没有可观测差异；核方法的收益只体现在非线性数据上。

除预测质量外，两种核的**计算开销**也不同。SVM 的训练需要构建 $n \times n$ 的 Gram 核矩阵 $\mathbf{K}_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$：线性核可通过 $\mathbf{X}\mathbf{X}^{\mathsf{T}}$ 一次矩阵乘法（BLAS 加速）完成，而 RBF 核需逐对计算平方距离并作指数运算。表 4 给出在 $n = 150$ 个标准化样本上的实测对比（每种核重复 500 次取均值）。

表 4: Gram 核矩阵 $\mathbf{K} = \mathbf{K}(\mathbf{X}, \mathbf{X})$ 的单次构建耗时（$n = 150$ 标准化鸢尾花样本，重复 500 次取均值）

核函数	计算方式	单次耗时（µs）
线性核	$\mathbf{X}\mathbf{X}^{\mathsf{T}}$（BLAS 矩阵乘法）	14.54
RBF 核	pairwise 距离 + exp	160.47
耗时比（RBF / 线性）	—	$\approx 11\times$

可见 RBF 核构建 Gram 矩阵的耗时约为线性核的 11 倍：线性核可完全委派给 BLAS 的矩阵乘法，而 RBF 核的逐对距离与指数运算无法享受同等优化（耗时的绝对值受硬件与运行环境影响，但量级差异稳定）。需要说明的是，在 $n = 150$ 的小样本下该开销绝对值很小（亚毫秒级），完整训练时间主要由 SMO 的迭代次数决定；但 Gram 矩阵构建的复杂度为 $O(n^2)$，随样本量增大线性增长，在大样本场景下将成为 RBF 核的主要瓶颈——这正是“RBF 核以**更高的计算开销** 换取更强的非线性表达能力的精度—开销权衡（Trade-off）”。

6.5 敏感性分析

为考察上述结论对关键因素的稳健性，本节从三个维度做敏感性分析。

表 5: 实验 D：C 敏感性（鸢尾花，线性核）——训练/CV 准确率与支持向量数随 C 的变化（分层 5 折 $\times$ 5 次重复的均值）

C	训练准确率	CV 准确率	支持向量数
0.001	66.67%	66.67%	81
0.01	94.70%	94.40%	81
0.1	99.33%	99.33%	33
1	99.37%	99.33%	11
10	99.93%	99.60%	5
100	100.00%	99.60%	4
1000	100.00%	99.60%	4

1. **对核参数 γ 的敏感性：**γ 扫描（表 3、图 4）显示，CV 准确率在较宽的 γ 区间（$[0.01, 3.2]$）内稳定在 99.33%，仅当 γ 过小（≤ 0.003，欠拟合）或过大（≥ 10，过拟合）时才明显下降。这说明核方法在“合理的 γ”范围内对参数不敏感，且“欠拟合→最优→过拟合”的翻转边界清晰可见。
2. **对惩罚参数 C 的敏感性：**固定线性核扫描 $C \in [10^{-3}, 10^{3}]$（表 5），CV 准确率在 $C \geq 0.1$ 时稳定在 $99.33\% \sim 99.60\%$，仅当 $C \leq 0.01$ 时因软间隔过松而明显欠拟合（$66.67\% \sim 94.40\%$）。支持向量数随 C 增大而**单调减少**（$81 \to 4$），反映模型由软间隔向硬间隔过渡——C 越大越接近硬间隔，所需支持向量越少。本文取 $C = 1$ 恰位于稳定平台，结论对 C 高度稳健；C 更大时 CV 略升至 99.60%（差异约 0.27 个百分点，未超过一个标准误），符合“近线性数据下硬间隔略优” 的预期。
3. **对数据划分的敏感性：**主实验采用分层 5 折 $\times$ 10 次重复，报告的标准误（Fisher LDA 0.39%、线性/RBF SVM 0.21%）远小于模型间差异（约 1.13 个百分点），说明模型排序不因划分波动而改变，重复交叉验证已把“划分随机性”这一方差来源量化出来[9]。

6.6 算法行为与核技巧的可视化

为直观展示前文理论的运行行为，本节给出三组由代码实际运行生成的可视化结果（生成脚本 `make_figures.py`，协议与正文实验完全一致：鸢尾花单次 7 : 3 划分、种子 42、 RBF 核 $\gamma = 0.5$、$C = 1$）。

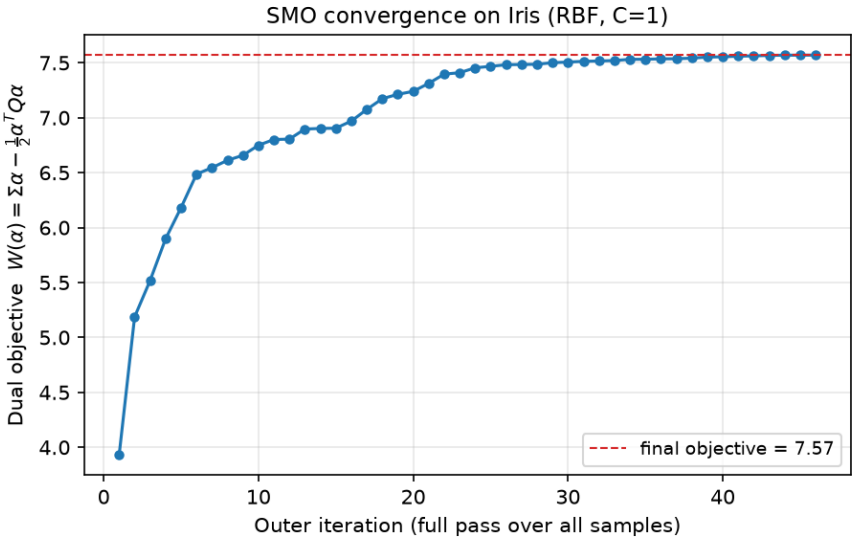


图 6: SMO 算法的收敛曲线：每一轮外层迭代（对所有样本完整扫描一次）后的对偶目标值 $W(\boldsymbol{\alpha}) = \sum_i \alpha_i - \frac{1}{2}\boldsymbol{\alpha}^{\mathsf{T}}\mathbf{Q}\boldsymbol{\alpha}$ （$\mathbf{Q}_{ij} = y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$）。目标值在约 20 轮内完成主要上升、 46 轮后收敛到平台（$W = 7.57$），且全程单调不减——两变量解析更新沿对偶问题的上升方向单调推进，能高效逼近对偶最优解。

三张图分别印证了前文的三个理论要点：图 6 验证了对偶问题的凸性与 SMO 求解的高效性（第 5.3 节）；图 7 直观呈现了“超平面仅由支持向量决定”的稀疏结构（第 5.1 节）；图 8 则给出了核技巧“隐式升维”的几何直观（第 5.4 节）——手工构造的 $z = x_1^2 + x_2^2$ 特征与 RBF 核的隐式映射异曲同工，但更便于直接观察。

7 代码实现

本节对照第 5 节的数学推导，简要说明实验代码（`svm_demo.py`）的核心算法实现细节。代码完全基于纯 NumPy 编写，零 scikit-learn 依赖，以保证对底层算法逻辑的精准控制。

7.1 核心算法与公式映射

代码直接实现了第 5 节推导的对偶问题求解与预测流程，具体映射如下：

- **对偶问题与 SMO 求解**（式 (9)）：由函数 `smo_simple` 实现。代码首先根据输入计算核矩阵 $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$，并将标签映射为 ± 1。在每次迭代中，通过两层循环更新拉格朗日乘子 $\boldsymbol{\alpha}$。

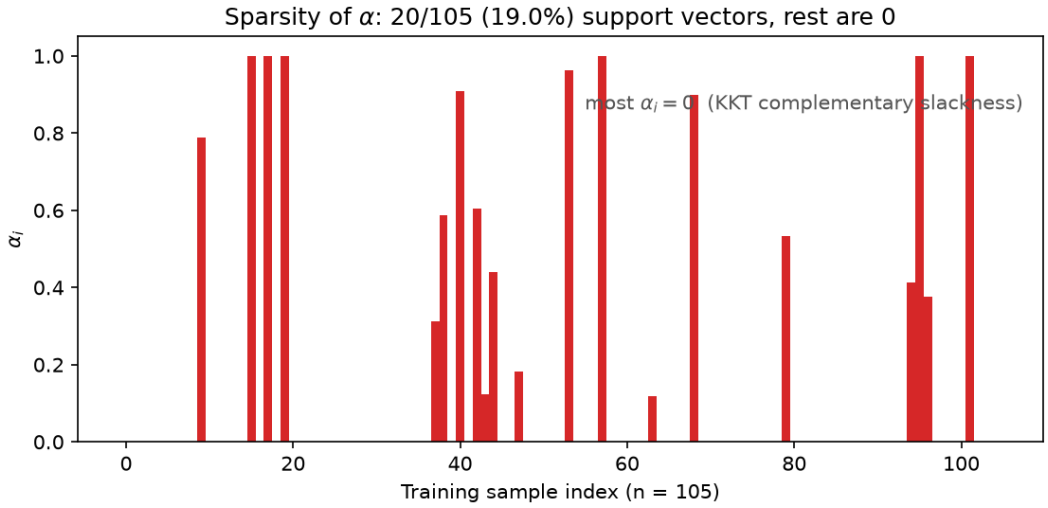


图 7: α 值的稀疏性分布：训练集 105 个样本中仅 20 个（19.0%）的 $\alpha_i > 0$（红色，支持向量；其中自由 SV 14 个、边界 SV 6 个），其余 85 个全部严格为 0。这正是 KKT 互补松弛条件 $\alpha_i[y_i f(\mathbf{x}_i) - 1] = 0$ 带来的稀疏结构的直接体现——决策超平面仅由这少数支持向量决定。

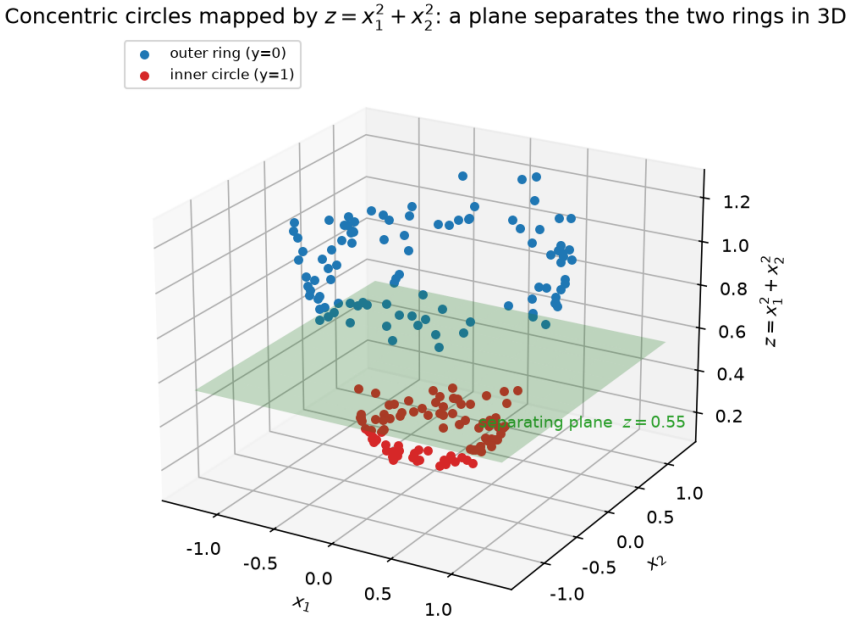


图 8: 核技巧升维的 3D 直观图：将同心圆数据经手工特征 $z = x_1^2 + x_2^2$ 映射到三维后，内圆（$z \approx 0.25$，红）与外环（$z \approx 1$，蓝）在 z 轴上自然分层，一张水平面 $z = 0.55$ 即可完美分离两类——低维空间中的圆形边界，在映射后的特征空间中只是一张“平坦的超平面”。

- **决策函数与预测**：决策函数实现为 $f(\mathbf{x}) = \sum_j \alpha_j y_j K(\mathbf{x}_j, \mathbf{x}) + b$。预测时（`svm_predict`）直接通过 $f(\mathbf{x}) > 0$ 判定类别。
- **支持向量的识别**：在模型拟合完成后，通过 `alphas > 1e-4` 筛选出支持向量，并进一步区分自由支持向量（$0 < \alpha < C$）与边界支持向量（$\alpha \approx C$）。
- **核函数实现**（式 (11)）：代码将核函数统一为 $K(a, b)$ 接口。线性核直接计算内积 $K = ab^{\mathsf{T}}$，RBF 核实现为 $K = \exp(-\gamma\|a - b\|^2)$。
- **合页损失的等价性**：代码并未直接对包含合页损失的原问题（式 (6)）进行梯度下降，而是求解由其 KKT 条件推导出的等价对偶问题，保证了全局最优解的获取。

7.2 SMO 算法关键细节

1. 乘子的成对更新与裁剪 由于等式约束 $\sum_i \alpha_i y_i = 0$ 的存在，SMO 每次选取一对 i, j 进行优化，且必须同步更新以保持约束。对于两变量子问题，代码根据误差项 E_i, E_j 和核矩阵元素，计算解析解 $\alpha_j^{\text{new}} = \alpha_j^{\text{old}} - y_j(E_i - E_j)/\eta$（其中 $\eta = 2K_{ij} - K_{ii} - K_{jj}$）。随后，将更新后的 α_j 裁剪到由盒约束和等式约束共同决定的区间 $[L, H]$ 内，并同步更新 α_i。

2. 偏置 b 的计算 求出 $\boldsymbol{\alpha}$ 后，偏置 b 的更新利用了位于间隔边界上的自由支持向量（满足 $0 < \alpha < C$ 及 $y_i f(\mathbf{x}_i) = 1$）。具体实现中，分别计算由样本 i 和样本 j 推导出的偏置候选值 b_1 与 b_2。若其中任一乘子位于 $(0, C)$ 区间内，则直接取其对应值；若两者均在边界上，则取两者的平均值作为最终的 b，以提高数值稳定性。

7.3 模型评估与数据防泄露

标准化处理：RBF 核对特征尺度敏感，代码中封装了 `standardize` 函数。为防止测试集信息泄露进训练过程，该函数仅在当前交叉验证的**训练折**上拟合均值和方差，再将其应用于验证折。相比之下，Fisher LDA 因判别方向不受特征缩放影响，故未施加标准化。

数值稳定性保障：为避免计算风险，代码在多处加入了保护机制。例如，在求解 Fisher LDA 时，对类内散布矩阵叠加 10^{-8} 的单位阵正则化，防止矩阵奇异导致的求逆失败；在标准化计算时，若某特征方差为 0 则强制置其标准差为 1，防止除零异常。

可复现性：数据划分、SMO 的随机变量选取以及合成数据生成等所有随机源，均固定了随机种子，确保文中报告的交叉验证结果与敏感性分析数据可被完全复现。

8 结论

8.1 主要研究结论

本文从线性分类基线（Fisher LDA）出发，系统介绍了支持向量机（SVM）的核心理论脉络：从最大间隔原则给出泛化意义下的最优线性边界，到支持向量决定超平面的稀疏性；从软间隔与合页损失引入对噪声的容忍，再到对偶问题将训练化为凸二次规划并自然催生出核技巧。在实践层面，

本文以核函数为唯一的改进方向，在分层 5 折 × 10 次重复交叉验证的严格协议下完成了对比实验，形成了从理论推导到工程落地的完整闭环。

实验的量化结论主要体现在以下三个方面：

1. **非线性数据的显著增益**：在强非线性的同心圆合成数据上，RBF 核将交叉验证准确率从线性核的 52.35% 跃升至 100.00%。这直观且有力地验证了核技巧将低维线性不可分问题映射到高维空间解决的核心价值。
2. **近线性数据上的奥卡姆剃刀**：在近线性的鸢尾花前两维数据上，线性核与 RBF 核的准确率并列（均为 99.33%）。依据一倍标准误（1se）规则，在性能无显著差异时应优先选择结构更简单的模型，因此线性模型是该数据集下的最优选择。
3. **复杂度参数的动态演变**：RBF 核的 γ 参数扫描实验清晰展示了模型从“欠拟合”到“最优拟合”再到“过拟合”的翻转过程。在这一过程中，作为模型复杂度代理指标的支持向量数量（Number of SVs）随之呈现典型的 U 形变化趋势，印证了偏差-方差权衡理论。

8.2 结论适用范围与局限

需要强调的是，上述结论具有严格的适用边界：其仅适用于“Iris 前两维特征、setosa 与其余类二分类、样本量约 150、分层 5 折 × 10 次重复”这一特定实验设定。不能将其过度外推为“Fisher 判别普遍优于/劣于其他线性方法”，或“核方法在任何场景下都必然带来性能提升”。此外，本文报告的性能指标均基于 0-1 损失下的准确率，并未进行平方损失下的偏差—方差定量分解，这在一定程度上限制了结论在回归或概率输出场景下的解释力。

8.3 后续研究方向

基于当前实验结果，后续工作可从以下三个维度展开：

- **超参数自动化寻优**：当前的 C 与 γ 仅基于基准值设定并作单向扫描。未来可引入网格搜索或贝叶斯优化，在交叉验证框架下寻找全局最优参数组合，以充分释放核方法的潜力。
- **特征维度扩展与充分性检验**：将特征从 2 维扩展至完整的 4 维，观察线性核与 RBF 核之间的性能差距是缩小还是扩大。若差距显著缩小，则说明前两维特征已捕获了主要判别信息；若差距拉大，则说明后两维存在更多非线性结构。
- **多模型横向对照**：引入逻辑回归、决策树[4]以及集成学习方法（如 Bagging 与随机森林[5]）进行多维度的泛化性能对比。需要注意的是，由于本文数据集属于低维小样本，引入随机森林等复杂模型时，需警惕其降低方差的幅度有限，甚至可能因过度拟合噪声而表现不佳。

参考文献

[1] 薛薇. 《Python机器学习：原理与实践》. 中国人民大学出版社, 2021（第 8 章：数据预测建模——支持向量机）.

[2] B. E. Boser, I. M. Guyon, V. N. Vapnik. A training algorithm for optimal margin classifiers. In *Proceedings of the 5th Annual Workshop on Computational Learning Theory (COLT)*, 144–152, 1992.

[3] S. Boyd, L. Vandenberghe. *Convex Optimization*. Cambridge University Press, 2004.

[4] L. Breiman, J. H. Friedman, R. A. Olshen, C. J. Stone. *Classification and Regression Trees*. Wadsworth, 1984.

[5] L. Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.

[6] C. Cortes, V. N. Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.

[7] R. A. Fisher. The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2):179–188, 1936.

[8] T. Heskes. Bias-variance decompositions: the exclusive privilege of Bregman divergences. *arXiv:2501.18581*, 2025.

[9] R. Kohavi. A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 1137–1145, 1995.

[10] J. C. Platt. Sequential Minimal Optimization: A fast algorithm for training support vector machines. Microsoft Research Technical Report MSR-TR-98-14, 1998.

[11] V. N. Vapnik. *The Nature of Statistical Learning Theory*. Springer, 1995.